Modelo híbrido de aprendizado de máquina e análise multicritério para classificação de risco de queimadas no estado do Pará

1st Eneas Monteiro Sousa
Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal do Pará (UFPA)
Belém, Pará
eneassousacontatos@gmail.com

2rd Marcos Fernando Soares Costa
Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal do Pará (UFPA)
Belém, Pará
marcosnandosc@gmail.com

3nd Edson Manoel Rodrigues e Silva
Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal do Pará (UFPA)
Belém, Pará
edsonmanoelrs28@gmail.com

***Resumo*—As queimadas representam um problema ambiental de grande escala na região amazônica, com impactos diretos sobre a biodiversidade, o clima e a saúde pública. Seu monitoramento é complexo devido à natureza multifatorial do fenômeno, que envolve condicionantes climáticos, ambientais e antrópicos. Neste trabalho, propõe-se um pipeline integrado que combina algoritmos de aprendizado de máquina (Random Forest, Extra Trees e XGBoost) com o método de análise multicritério ELECTRE Tri-B para classificação de risco de queimadas nos 144 municípios do estado do Pará, no período de 2019 a 2025. Os modelos foram treinados a partir de variáveis climáticas mensais obtidas do NASA POWER e do histórico de focos de calor do NASA FIRMS, utilizando divisão cronológica estrita para evitar vazamento de dados. O XGBoost, selecionado pelo melhor desempenho, obteve AUC-ROC de 0,935 no conjunto de teste e *recall* de 0,80 para eventos de foco relevante. As probabilidades geradas foram submetidas ao ELECTRE Tri-B, classificando os municípios em quatro categorias ordenadas de risco. Os resultados demonstram o potencial da abordagem para apoiar o monitoramento ambiental e a definição de áreas prioritárias de prevenção na região.**

***Index Terms*—Queimadas; Aprendizado de máquina; Análise multicritério; Pará**

I. Introdução

A floresta amazônica desempenha funções ambientais estratégicas em escala global, influenciando a regulação climática, o armazenamento de carbono e processos hidrológicos regionais [1]. Em 2025, o Brasil registrou mais de 134 mil focos de queimadas, dos quais cerca de 18 mil ocorreram no estado do Pará, representando aproximadamente 13,4% do total nacional, segundo o INPE [2].

A ocorrência de queimadas resulta da interação entre fatores ambientais e antrópicos, incluindo desmatamento, fragmentação da paisagem e variabilidade climática, fatores amplamente associados à dinâmica do fogo na Amazônia [3]. A análise desse fenômeno requer abordagens capazes de integrar múltiplos indicadores ambientais derivados de dados geoespaciais [4]. Abordagens tradicionais frequentemente produzem representações contínuas ou índices agregados de risco, dificultando a definição de categorias operacionais para apoio à tomada de decisão [5]. Nesse contexto, técnicas de aprendizado de máquina têm se destacado pela capacidade de identificar padrões complexos em dados temporais e espaciais, enquanto métodos multicritério permitem transformar probabilidades contínuas em categorias ordenadas de risco com semântica operacional [6] [7].

Diante desse cenário, este trabalho tem como objetivo propor um pipeline integrado capaz de estimar, mensalmente, a probabilidade de risco de queimadas nos 144 municípios do estado do Pará, identificando aqueles com maior propensão à ocorrência de novos focos de calor nos meses subsequentes, a partir dos dados coletados no período de 2019 a 2025. A abordagem aplica algoritmos de aprendizado de máquina (Random Forest, Extra Trees e XGBoost) para predição mensal de focos de calor a partir de variáveis climáticas e históricas, com o método ELECTRE Tri-B para classificação dos municípios em categorias ordenadas de risco: baixo, moderado, alto e crítico. Os dados utilizados provêm de fontes públicas, incluindo NASA FIRMS, NASA POWER e IBGE.

II. Contexto Ambiental e Dinâmica das Queimadas na Amazônia

A região amazônica é um sistema socioambiental complexo, no qual fatores climáticos, ecológicos e de ocupação territorial interagem dinamicamente. A floresta regula o clima e influencia na precipitação, evapotranspiração e circulação atmosférica [1]. Entretanto, pressões antrópicas, como expansão agropecuária, mineração e grandes empreendimentos, alteram a cobertura do solo e o regime hidrológico, comprometendo os ecossistemas [8].

Nas últimas décadas, a expansão produtiva intensificou mudanças na paisagem associadas à remoção da cobertura florestal e ao uso do fogo como prática de manejo, contribuindo diretamente para o aumento da incidência de queimadas [9]. Dados do INPE indicam que, entre 2016 e 2025, o Brasil registrou mais de 2 milhões de focos de queimadas, com picos em 2019 e 2024 [2]. Nesse período, o estado do Pará concentrou cerca de 13% das ocorrências, totalizando

aproximadamente 300 mil registros. Em 2024, cerca de 30,8 milhões de hectares foram afetados no país, com a Amazônia como bioma mais impactado, incluindo aproximadamente 2,8 milhões de hectares no Pará.

Além dos fatores antrópicos, condições climáticas como deficit hídrico, variações na precipitação e aumento da temperatura da superfície influenciam a suscetibilidade a incêndios [3]. Dados do MapBiomas indicam que cerca de 64% da área impactada no Pará corresponde à vegetação nativa, evidenciando o risco à biodiversidade.

O avanço do sensoriamento remoto tem ampliado substancialmente a capacidade na Amazônia, permitindo acompanhar mudanças na paisagem em diferentes escalas espaciais e temporais. Plataformas como o NASA FIRMS possibilitam a detecção de focos de calor em tempo quase real, o mapeamento de alterações na cobertura do solo e a análise de padrões espaciais das queimadas. Essas fontes constituem a base de dados utilizada no presente trabalho e serão detalhadas na seção de metodologia.

III. Metodologia

A metodologia foi estruturada para classificar o risco de queimadas nos 144 municípios do estado do Pará por meio de um pipeline integrado que combina aprendizado de máquina e análise multicritério. O processo compreende cinco etapas sequenciais: aquisição e pré-processamento dos dados, construção do conjunto de atributos, treinamento e avaliação dos modelos de aprendizado de máquina, e classificação final por ELECTRE Tri-B.

A. Aquisição dos dados

Os dados foram obtidos de fontes públicas amplamente utilizadas na literatura científica. Os focos de calor foram coletados via NASA FIRMS [10], utilizando o sensor VIIRS S-NPP (*Standard Product*), que fornece dados históricos consolidados com maior confiabilidade para análises retroativas em comparação aos produtos de tempo quase real. As variáveis climáticas mensais — temperatura a 2 m (T2M), temperatura máxima (T2M_MAX), precipitação corrigida (PRECTOTCORR), umidade relativa (RH2M), velocidade do vento (WS2M) e radiação solar (ALLSKY_SFC_SW_DWN) — foram obtidas via NASA POWER [11]. Os limites territoriais e identificadores municipais foram fornecidos pelo IBGE [12]. Todos os dados abrangem o período de janeiro de 2019 a dezembro de 2025, com granularidade mensal e escala municipal.

Tabela 1
Fontes de dados utilizadas

Fonte	Tipo de dado	Formato	Acesso
NASA FIRMS	Focos de calor	CSV	API
NASA POWER	Variáveis climáticas	JSON	API
IBGE	Limites territoriais	GeoJSON	Download

B. Pré-processamento e Limpeza

Após a aquisição, os dados foram submetidos a um processo de ingestão automatizada por meio de APIs e arquivos estruturados. Os focos de calor do FIRMS passou por filtragem, onde foram descartadas as detecções classificadas com confiança baixa (confidence *low*) pelo sensor VIIRS, que apresentam maior taxa de falso positivo. Logo após, foi realizado um *spatial join* para restringir os focos aos limites dos municípios do Pará, descartando registros externos ao estado. O processo reduziu os 17.166 focos brutos para 9.765 registros válidos.

A harmonização das bases incluiu a padronização dos identificadores municipais para o código oficial do IBGE com 7 dígitos e a conversão das variáveis temporais para o formato *datetime*. Os focos de calor foram agregados mensalmente por município, gerando a série temporal utilizada como variável alvo do modelo.

C. Construção do Conjunto de Atributos

A partir das séries mensais por município, foram construídas as *features* preditivas utilizadas pelos modelos. O conjunto inclui três grupos de variáveis:

Histórico de focos: defasagens temporais de 1, 2 e 3 meses (focos_lag) e média móvel dos três meses anteriores (focos_media3m), calculadas por município para evitar vazamento entre séries distintas.

Variáveis climáticas: valores do mês corrente e defasados em 1 mês para cada variável do NASA POWER, além do acumulado de precipitação dos 3 meses anteriores (precip_acum3m), que captura o efeito cumulativo do déficit hídrico sobre a suscetibilidade ao fogo.

Sazonalidade: mês e trimestre do ano, permitindo ao modelo distinguir a estação seca (agosto–outubro) da estação chuvosa sem depender exclusivamente das variáveis climáticas.

Todas as defasagens foram calculadas com *shift* anterior ao mês corrente, garantindo que nenhuma *feature* incorpore informação futura (*data leakage*). As primeiras linhas de cada município com valores ausentes decorrentes das defasagens foram removidas, totalizando 4,8% das amostras.

D. Definição do Alvo e Divisão Temporal

A variável alvo (*target*) foi definida de forma binária: valor 1 indica que o número de focos no mês seguinte supera o limiar do p75 histórico do município, e 0 caso contrário. O limiar foi calculado individualmente por município utilizando apenas os dados de treino (2019–2022), evitando contaminação com os períodos de validação e teste. Essa estratégia por município, em contraste com um limiar global, respeita a heterogeneidade territorial do Pará, onde municípios de grande extensão como Altamira apresentam volumes de focos estruturalmente diferentes de municípios menores.

A divisão dos dados seguiu ordem cronológica estrita, conforme exigido para séries temporais:

Tabela 2
Divisão temporal dos dados

Conjunto	Período	Amostras
Treino	2019–2022	6.480
Validação	2023	1.728
Teste	2024–2025	3.456

E. Modelos de Aprendizado de Máquina

Foram treinados e comparados três algoritmos de classificação baseados em *ensemble* de árvores de decisão: Random Forest, Extra Trees e XGBoost [13]. O desbalanceamento entre classes (6,8% de amostras positivas) foi tratado com `class_weight="balanced"` no Random Forest e Extra Trees, e com `scale_pos_weight` proporcional à razão entre negativos e positivos no XGBoost.

O modelo XGBoost foi treinado com *early stopping*, monitorando a AUC-PR (*Area Under the Precision-Recall Curve*) no conjunto de validação, com interrupção após 30 iterações consecutivas sem melhoria. Essa métrica foi preferida à AUC-ROC como critério de parada por apresentar maior sensibilidade à classe minoritária em cenários de forte desbalanceamento [14], como o observado neste estudo. Adicionalmente, aplicou-se calibração isotônica de probabilidades (`CalibratedClassifierCV`, `method="isotonic"`) com base no conjunto de validação, com o objetivo de corrigir a distorção (compressão) das probabilidades induzida pelo uso de valores elevados de `scale_pos_weight` [15].

A avaliação preliminar foi conduzida por validação cruzada temporal (`TimeSeriesSplit`, $k = 3$), na qual o conjunto de treino é expandido progressivamente, preservando a ordem cronológica das observações. A seleção do modelo final baseou-se na AUC-ROC obtida no conjunto de validação. O limiar de decisão foi então otimizado segundo a métrica F_β, com $\beta = 2$, atribuindo maior peso ao *recall*. O limiar ótimo encontrado foi $\tau = 0{,}205$, substancialmente inferior ao valor convencional de $0{,}5$, o que reflete a necessidade de aumentar a sensibilidade do modelo à classe positiva minoritária, comportamento consistente com problemas de alta assimetria entre classes.

A granularidade mensal da série temporal assegura que cada observação represente um município ao longo de um mês completo, eliminando o risco de vazamento de informação decorrente de fragmentação temporal. Verificou-se, adicionalmente, que os limites de cada *fold* do `TimeSeriesSplit` coincidem com fronteiras mensais, garantindo uma separação temporal estrita entre os conjuntos de treino e validação.

F. Classificação por ELECTRE Tri-B

A probabilidade média por município, gerada pelo melhor modelo ao longo de todo o período, foi utilizada como entrada para o método ELECTRE Tri-B [7], que classifica os municípios em quatro categorias ordenadas de risco: baixo, moderado, alto e crítico.

O método compara cada município contra três perfis de referência (b_1, b_2, b_3) por meio de índices de concordância, discordância e credibilidade. A regra pessimista foi adotada: um município é alocado na categoria mais alta cujo perfil de referência é superado com credibilidade $\geq \lambda = 0{,}65$.

Os perfis foram calibrados proporcionalmente ao intervalo real das probabilidades observadas, e os limiares de indiferença (q), preferência (p) e veto (v) foram escalonados em 10%, 20% e 60% do intervalo, respectivamente.

Tabela 3
CATEGORIAS DE RISCO E PERFIS DE REFERÊNCIA

Categoria	Perfis	Limiares	Interpretação
Baixo	$< b_1$	q, p, v	Baixa suscetibilidade
Moderado	b_1–b_2	q, p, v	Suscetibilidade moderada
Alto	b_2–b_3	q, p, v	Alta suscetibilidade
Crítico	$> b_3$	q, p, v	Risco elevado e prioritário

IV. RESULTADOS

A aplicação do pipeline integrado permitiu classificar os 144 municípios do estado do Pará em categorias ordenadas de risco de queimadas. Os resultados são apresentados em três etapas: desempenho dos modelos de aprendizado de máquina, classificação final por ELECTRE Tri-B e distribuição espacial do risco.

A. Desempenho dos Modelos

A avaliação prévia por validação cruzada temporal ($k = 3$) indicou desempenho consistente do XGBoost ao longo do período analisado, com AUC-ROC médio de 0,924 $\pm$ 0,005.

Tabela 4
AUC-ROC POR FOLD NA VALIDAÇÃO CRUZADA TEMPORAL

Fold	Período de validação	AUC-ROC
1	até jul/2022	0,920
2	até mar/2024	0,931
3	até nov/2025	0,921
Média	—	**0,924 $\pm$ 0,005**

No treino final, os três modelos foram comparados pelo AUC-ROC no conjunto de validação (2023), com o XGBoost obtendo o melhor desempenho, conforme apresentado na Tabela 5.

Tabela 5
COMPARAÇÃO DOS MODELOS NO CONJUNTO DE VALIDAÇÃO

Modelo	AUC-ROC (validação)
Random Forest	0,941
Extra Trees	0,904
XGBoost	**0,966**

A avaliação no conjunto de teste (2024–2025) confirmou a capacidade discriminativa do modelo, com AUC-ROC de 0,940 (Tabela 6). O limiar de decisão otimizado pelo F_2-*score* (0,205) resultou em *recall* de 0,82 para a classe positiva, capturando 82% dos eventos reais de foco relevante.

Tabela 6
DESEMPENHO DO XGBOOST NO CONJUNTO DE TESTE (2024–2025)

Classe	Precision	Recall	F1	Suporte
Sem foco	0,99	0,91	0,95	3.267
Com foco	0,36	0,82	0,50	189
AUC-ROC	**0,940**			

B. Curva Precision-Recall

A Figura 1 apresenta as curvas Precision-Recall dos três modelos no conjunto de validação. O XGBoost obteve a maior *Average Precision* (AP = 0,74), superando o Random

Forest (AP = 0,72) e o Extra Trees (AP = 0,71). A linha tracejada indica o ponto de operação selecionado pelo F_2-*score* ($\tau = 0{,}205$, recall = 0,82), no qual o modelo aceita precisão de 0,36 em troca de detectar 82% dos eventos reais de foco — decisão justificada pela assimetria de custos do monitoramento ambiental, onde falsos negativos são mais custosos que falsos positivos [17].

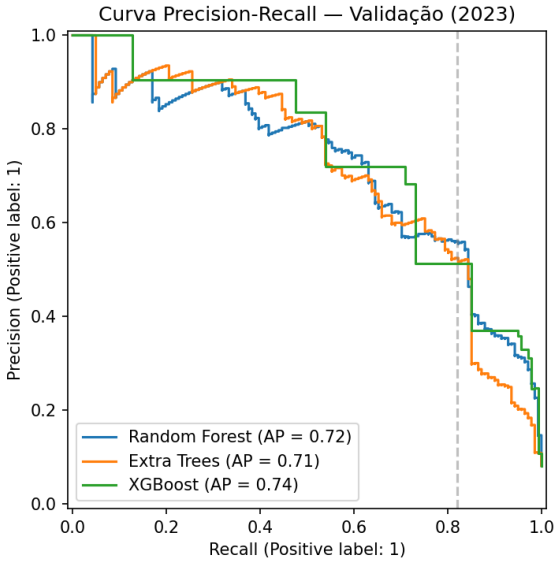


Figura 1. Curva Precision-Recall dos três modelos na validação (2023). A linha tracejada indica o ponto de operação com $\tau = 0{,}205$.

Observa-se que os três modelos mantêm precisão acima de 0,80 para recall inferior a 0,6 — quando operam com alta certeza, acertam a maioria dos alarmes. A partir desse ponto, a precision cai progressivamente à medida que o modelo amplia a busca por focos, penalizando mais o Extra Trees e o Random Forest do que o XGBoost, que preserva maior área sob a curva ao longo de toda a faixa de recall.

C. Análise de Sensibilidade

Para verificar a robustez da escolha do modelo final, foram conduzidos diversos experimentos variando os principais hiperparâmetros dos três algoritmos: profundidade máxima das árvores (`max_depth` entre 8 e 40), número de estimadores do XGBoost (`n_estimators` entre 40 e 600) e uso ou não do parâmetro `class_weight="balanced"` no Random Forest e Extra Trees.

Tabela 7
ANÁLISE DE SENSIBILIDADE — VARIAÇÃO DE N_ESTIMATORS DO XGBOOST

n_estimators	AUC-ROC (val)	AUC-ROC (teste)	Recall
10	0,964	0,942	0,83
20	0,962	0,937	0,84
30	0,965	0,939	0,82
40	**0,966**	**0,940**	**0,82**
45	0,967	0,939	0,83
100	0,966	0,935	0,80
500	0,966	0,935	0,80
600	0,966	0,935	0,80

O XGBoost apresentou AUC-ROC de validação estável entre 0,962 e 0,967 em todas as configurações testadas. Modelos com número reduzido de estimadores ($n \leq 45$) produziram AUC-ROC no teste entre 0,937 e 0,942, ligeiramente superior aos modelos com $n \geq 100$ (0,935). O modelo com `n_estimators=40` foi selecionado como configuração final por apresentar o melhor equilíbrio entre AUC-ROC (0,940) e estabilidade, sugerindo que os padrões sazonais e climáticos associados às queimadas no Pará são estruturalmente fortes o suficiente para serem capturados com um número reduzido de árvores, resultado consistente com a literatura sobre dados ambientais com forte componente sazonal [3].

O experimento com menor número de estimadores (`n_estimators=40`) produziu o melhor AUC-ROC no teste (0,940) e o maior *recall* (0,82), sugerindo que os padrões sazonais e climáticos associados às queimadas no Pará são estruturalmente fortes o suficiente para serem capturados com um número reduzido de árvores. Random Forest e Extra Trees mostraram sensibilidade maior à variação de hiperparâmetros, sem contudo superar o XGBoost em nenhuma configuração testada.

D. Análise SHAP

A análise SHAP (*SHapley Additive exPlanations*) [18] aplicada ao XGBoost no conjunto de teste revelou que a variável `mes` é o preditor dominante, com impacto fortemente assimétrico: meses do segundo semestre (estação seca, agosto–outubro) contribuem positivamente para a probabilidade de foco, enquanto meses do primeiro semestre exercem efeito supressor.

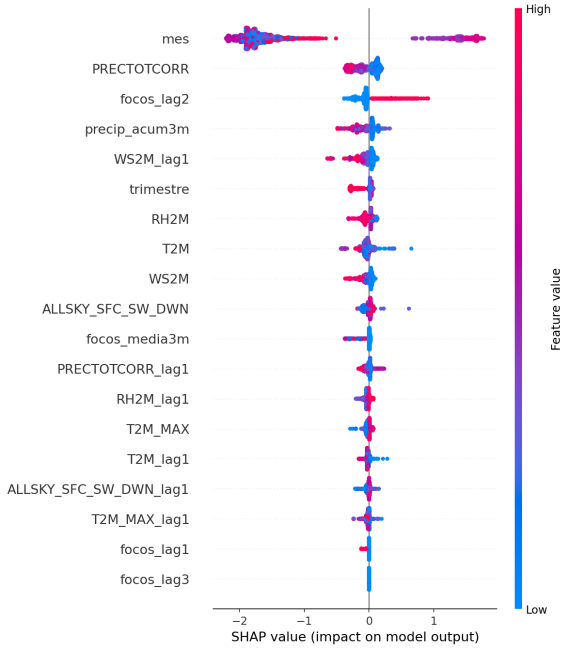


Figura 2. Análise SHAP - impacto das *features* na predição do XGBoost. Cada ponto representa um município em um mês específico. A cor indica o valor da *feature* (vermelho = alto, azul = baixo) e a posição horizontal indica a direção e magnitude do impacto na probabilidade de ocorrência de foco.

Entre as variáveis de histórico, `focos_lag2` apresentou maior impacto que `focos_lag1`, sugerindo que o padrão de ocorrência de focos dois meses anteriores é mais informativo para a predição do que o mês imediatamente anterior, possivelmente reflexo do tempo de acumulação de condições favoráveis à ignição. As variáveis climáticas (`PRECTOTCORR`, `WS2M_lag1`, `RH2M`) apresentaram impacto secundário e concentrado próximo ao zero, atuando como amplificadores do risco latente estabelecido pela sazonalidade e pelo histórico de focos.

E. Classificação por ELECTRE Tri-B

A probabilidade média por município gerada pelo XGBoost foi submetida ao método ELECTRE Tri-B, resultando na seguinte distribuição de risco entre os 144 municípios do Pará:

Tabela 8
DISTRIBUIÇÃO DOS MUNICÍPIOS POR CATEGORIA DE RISCO

Categoria	Municípios	%
Baixo	33	22,9%
Moderado	45	31,2%
Alto	35	24,3%
Crítico	31	21,5%
Total	**144**	**100%**

F. Distribuição Espacial do Risco

A Figura 3 apresenta a distribuição espacial das categorias de risco para os municípios do Pará. O padrão resultante revela uma divisão territorial marcante entre as porções norte e sul do estado.

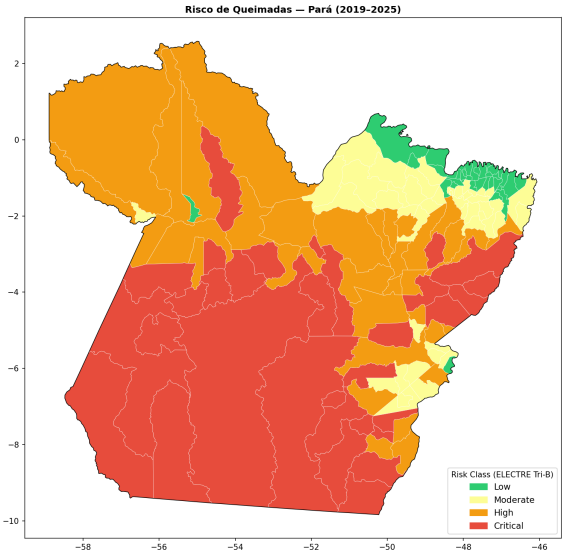


Figura 3. Distribuição espacial do risco de queimadas – Pará (2019–2025).

A categoria crítico (vermelho) predomina na porção sul e sudoeste do estado, abrangendo municípios de grande extensão territorial historicamente associados à fronteira agropecuária e ao avanço do desmatamento na Amazônia. Essa região coincide com o denominado ”arco do desmatamento”, faixa que se estende do leste do Pará ao norte do Mato Grosso e concentra as maiores pressões antrópicas sobre a cobertura florestal amazônica [16]. Apesar de representar 18,8% dos municípios, essa categoria ocupa uma fração expressiva da área total do estado, reflexo do porte dos municípios nessa região, como Altamira e São Félix do Xingu, que estão entre os maiores do Brasil em extensão territorial.

A categoria alto (laranja) concentra-se predominantemente no oeste e em áreas dispersas do centro-leste, totalizando 26,4% dos municípios. Essa distribuição coincide com regiões de intensa pressão sobre a cobertura florestal e variabilidade climática acentuada [3].

As categorias moderado (amarelo) e baixo (verde) concentram-se no nordeste do estado, região com maior densidade municipal e melhor conservação da cobertura florestal. Os municípios classificados como baixo risco estão predominantemente na faixa litorânea e na região metropolitana de Belém.

V. DISCUSSÃO

O AUC-ROC de 0,940 no conjunto de teste indica boa capacidade discriminativa do modelo mesmo sob forte desbalanceamento de classes, no qual apenas 6,8% das amostras corresponderam a eventos de foco relevante. Esse padrão reflete a própria dinâmica espaço-temporal das queimadas no estado do Pará, onde a maior parte dos municípios permanece sem ocorrências significativas durante a estação chuvosa. Neste contexto, a utilização de `scale_pos_weight`, aliada à calibração isotônica de probabilidades, mostrou-se decisiva para a qualidade da classificação: comparado a um cenário sem essa ponderação — no qual o desbalanceamento é compensado apenas pelo ajuste do limiar de decisão —, o uso de `scale_pos_weight` elevou o AUC-ROC no conjunto de teste de 0,917 para 0,940 e a precisão da classe positiva de 0,28 para 0,36, ainda que ao custo de uma leve redução no *recall* (de 0,90 para 0,82). Isso indica que a ponderação durante o treinamento melhora a capacidade discriminativa real do modelo, em vez de apenas deslocar o limiar de decisão para compensar o desbalanceamento.

A escolha do F_2-*score* como critério de otimização do limiar reflete a assimetria de custos do problema: em monitoramento ambiental, o custo de não detectar um evento real de queimada supera o custo de emitir um alarme desnecessário [17]. O *recall* de 0,82 obtido no teste confirma que o modelo captura a maior parte dos eventos relevantes, ainda que ao custo de uma precisão mais baixa (0,36).

Adicionalmente, a integração dos resultados com o método multicritério ELECTRE Tri-B permitiu categorizar os riscos em níveis acionáveis. A distribuição das previsões no estado, com 21,5% dos municípios em nível ’Crítico’ e 24,3% em nível ’Alto’, guarda forte correlação visual com o arco do desmatamento. Isso indica que o modelo não apenas aprendeu os padrões climáticos globais (via NASA POWER), mas também a vulnerabilidade geográfica específica das regiões sob maior pressão antrópica no Pará.

VI. CONCLUSÕES

Este trabalho apresentou um pipeline integrado de aprendizado de máquina e análise multicritério para classificação de

risco de queimadas nos 144 municípios do estado do Pará, no período de 2019 a 2025. A abordagem combinou algoritmos de *ensemble* (Random Forest, Extra Trees e XGBoost) para predição mensal de focos de calor, com o método ELECTRE Tri-B para tradução das probabilidades contínuas em categorias ordenadas de risco territorial.

O modelo XGBoost, selecionado pelo melhor desempenho na validação, obteve AUC-ROC de 0,940 no conjunto de teste e *recall* de 0,82 para eventos de foco relevante, demonstrando boa capacidade discriminativa mesmo sob forte desbalanceamento de classes. A ponderação via `scale_pos_weight` e a calibração isotônica de probabilidades, aliadas à definição de limiares por município, mostraram-se decisivas para a qualidade dos resultados, melhorando a capacidade discriminativa do modelo e respeitando a heterogeneidade territorial do estado.

Um achado relevante da análise SHAP diz respeito ao comportamento das variáveis de histórico de focos: `focos_lag2` apresentou impacto superior ao de `focos_lag1`, contrariando a expectativa de que o mês imediatamente anterior seria o preditor mais forte. Uma possível explicação é que, durante a estação seca, a variável `mes` já captura o contexto temporal imediato, tornando `focos_lag1` parcialmente redundante. O sinal de dois meses anteriores, por sua vez, carrega informação adicional sobre a tendência de acumulação de condições favoráveis à ignição, contribuindo de forma mais independente para a predição.

Por fim, a classificação final via ELECTRE Tri-B permitiu uma distribuição consistente entre as quatro categorias de risco, oferecendo uma visão espacial clara que converge com as áreas historicamente críticas de desmatamento no estado.

A. Limitações

Algumas limitações devem ser consideradas na interpretação dos resultados. As probabilidades geradas pelo modelo permanecem em um intervalo estreito (0,028–0,152), reflexo do forte desbalanceamento dos dados e da natureza esparsa dos eventos de queimada. Embora a calibração isotônica tenha reduzido parcialmente esse efeito, a compressão limita a separabilidade entre categorias no ELECTRE Tri-B.

Adicionalmente, o modelo é de natureza preditiva, estima a probabilidade de ocorrência de focos no mês seguinte, e não substitui análises causais sobre os determinantes estruturais das queimadas. A ausência de variáveis de uso e cobertura do solo (MapBiomas) e temperatura da superfície terrestre (LST), podem representar uma limitação diante o trabalho realizado.

De forma geral, o pipeline proposto contribui para o monitoramento ambiental na Amazônia e oferece uma base analítica replicável para o apoio à formulação de políticas públicas voltadas à prevenção e gestão de queimadas em escala regional.

Referências

[1] Fearnside, P. M. (2005). Deforestation in brazilian amazonia: History, rates, and consequences. Conservation Biology, 19(3):680–688.

[2] INPE (2025). Programa queimadas - banco de dados de queimadas (bdqueimadas). Acesso em: 2026.

[3] Aragão, L. E. O. C., Anderson, L. O., and Fonseca, M. G. (2018). 21st century drought-related fires counteract the decline of amazon deforestation carbon emissions. Nature Communications, 9:536.

[4] Libonati, R. et al. (2022). Multicriteria severity indicator using remote sensing for forest firefighting dispatch in the brazilian amazon. IEEE Geoscience and Remote Sensing Letters, 19:1–5.

[5] Silva, J. M., Santos, L. R., and Ferreira, A. C. (2025). A spatial multicriteria framework to define priorities in wildfire management programs. Frontiers in Forests and Global Change, 8:104521.

[6] Bozca, M. and Akıncı, H. (2025). A multi-criteria forest fire danger assessment system on gis using literature-based model and analytical hierarchy process model. Sustainability, 17(2):784.

[7] Roy, B. (1996). Multicriteria Methodology for Decision Aiding. Kluwer Academic Publishers.

[8] Winemiller, K. O. et al. (2016). Balancing hydropower and biodiversity in the amazon, congo, and mekong. Science, 351(6269):128–129.

[9] Nepstad, D. et al. (2014). Slowing amazon deforestation through public policy and interventions in beef and soy supply chains. Science, 344(6188):1118–1123.

[10] NASA (2024). Fire information for resource management system (firms). Acesso em: 26 mar. 2026.

[11] NASA Langley Research Center (2024). POWER: Prediction of Worldwide Energy Resources. Disponível em: https://power.larc.nasa.gov. Acesso em: 2025.

[12] IBGE (2023). Base cartográfica contínua do brasil e dados municipais. Acesso em: 26 mar. 2026.

[13] Yang C, Yao P, Wang Q, Wang S, Xing D, Wang Y, Zhang J. XGBoost-Based Susceptibility Model Exhibits High Accuracy and Robustness in Plateau Forest Fire Prediction. Forests. 2026; 17(1):74.

[14] Davis, J. and Goadrich, M. (2006). The relationship between Precision-Recall and ROC curves. In Proceedings of the 23rd International Conference on Machine Learning (ICML), pages 233–240.

[15] Zadrozny, B. and Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. In *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 694–699.

[16] Oviedo, A., Lima, W. P., and Augusto, C. (2019). O arco do desmatamento e suas flechas. Instituto Socioambiental, São Paulo.

[17] Bowman, D. M. J. S., Balch, J. K., and Artaxo, P. (2009). Fire in the earth system. Science.

[18] Lundberg, S.M. and Lee, S.I. (2017) A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems (NeurIPS), 4766-4777.